



Машинное обучение

Методы восстановления регрессии

Смирнов Илья

Руководитель направления

Содержание

- Метод наименьших квадратов
- Геометрический смысл
- Регуляризация
- Сингулярное разложение

Метод наименьших квадратов

$$X = \mathbf{R}^n, Y = \mathbf{R}$$

$$\text{Модель: } a(x) = f(x, \alpha)$$

Метод наименьших квадратов (МНК):

$$Q(\alpha, X^l) = \sum_{i=1}^l w_i (f(x_i, \alpha) - y_i)^2 \rightarrow \min \text{ по } \alpha$$

w_i — вес, степень важности i -го объекта

Многомерная линейная регрессия

$f_1(x), \dots, f_n(x)$ — числовые признаки;

Модель
$$f(x, \alpha) = \sum_{j=1}^n \alpha_j f_j(x), \quad \alpha \in \mathbb{R}^n$$

Матричная форма:

$$F_{\ell \times n} = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \dots & \dots & \dots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix}, \quad y_{\ell \times 1} = \begin{pmatrix} y_1 \\ \dots \\ y_\ell \end{pmatrix}, \quad \alpha_{n \times 1} = \begin{pmatrix} \alpha_1 \\ \dots \\ \alpha_n \end{pmatrix}$$

$$Q(\alpha, X^\ell) = \sum_{i=1}^{\ell} (f(x_i, \alpha) - y_i)^2 = \|F\alpha - y\|^2 \rightarrow \min_{\alpha}$$

Система уравнений

Необходимое условие минимума:

$$\frac{\partial Q}{\partial \alpha}(\alpha) = 2F^T(F\alpha - y) = 0$$

$$F^T F \alpha = F^T y$$

$F^T F$ — ковариационная матрица $n \times n$ набора признаков f_1, \dots, f_n

Решение системы: $\alpha^* = (F^T F)^{-1} F^T y = F^+ y$

Значение функционала:

$$Q(\alpha^*) = \|P_F y - y\|^2$$

где P_F - проекционная матрица:


$$P_F = FF^+ = F(F^T F)^{-1} F^T$$

Геометрический смысл

- Любой вектор вида $\mathbf{y} = \mathbf{F}\boldsymbol{\alpha}$ – линейная комбинация признаков

$$\|\mathbf{F}\boldsymbol{\alpha} - \mathbf{y}\|^2 \rightarrow \min_{\boldsymbol{\alpha}}$$


- $\mathbf{F}\boldsymbol{\alpha}^*$ = аппроксимация вектора \mathbf{y} с наименьшим квадратом тогда и только тогда, когда $\mathbf{F}\boldsymbol{\alpha}^*$ – проекция вектора \mathbf{y} на подпространство признаков



Пример: аппроксимация многочленами


- Данные: $\sin(x)$ + случайный шум

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_j x^j$$




Многочлен нулевой степени $M=0$

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_jx^j$$




Многочлен степени M=3

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_jx^j$$



Многочлен степени M=9

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_jx^j$$



Гребневая регрессия: Ridge regression

Штраф за увеличение нормы вектора весов $\|\alpha\|$:


$$Q_{\tau}(\alpha) = \|F\alpha - y\|^2 + \frac{1}{\sigma} \|\alpha\|^2$$

Модифицированное МНК-решение $\tau = 1/\sigma$
(τI_n — «гребень»):

$$\alpha_{\tau}^* = (F^T F + \tau I_n)^{-1} F^T y$$

Многочлен 9 степени RidgeRegression

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_jx^j$$



Сингулярное разложение

Произвольная $\ell \times n$ -матрица представима в виде *сингулярного разложения* (singular value decomposition, SVD):

$$F = VDU^T.$$

Основные свойства сингулярного разложения:

- ❶ $\ell \times n$ -матрица $V = (v_1, \dots, v_n)$ ортогональна, $V^T V = I_n$, столбцы v_j — собственные векторы матрицы FF^T ;
- ❷ $n \times n$ -матрица $U = (u_1, \dots, u_n)$ ортогональна, $U^T U = I_n$, столбцы u_j — собственные векторы матрицы $F^T F$;
- ❸ $n \times n$ -матрица D диагональна, $D = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$, $\lambda_j \geq 0$ — собственные значения матриц $F^T F$ и FF^T .

Решение МНК через сингулярное разложение

$$\alpha^* = (F^T F)^{-1} F^T y = F^+ y$$

$$F^+ = (UDV^T VDU^T)^{-1} UDV^T = UD^{-1} V^T = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j v_j^T$$

$$\alpha^* = F^+ y = UD^{-1} V^T y = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j (v_j^T y)$$

$$F \alpha^* = P_F y = (VDU^T) UD^{-1} V^T y = VV^T y = \sum_{i=1}^n v_i (v_i^T y)$$

$$\|\alpha^*\|^2 = \|D^{-1} V^T y\|^2 = \sum_{j=1}^n \frac{1}{\lambda_j} (v_j^T y)^2$$

Проблема мультиколлинеарности

Число обусловленности $n \times n$ -матрицы Σ

$$\mu(\Sigma) = \|\Sigma\| \|\Sigma^{-1}\| = \frac{\max_{u: \|u\|=1} \|\Sigma u\|}{\min_{u: \|u\|=1} \|\Sigma u\|} = \frac{\lambda_{\max}}{\lambda_{\min}}$$

При умножении обратной матрицы на вектор, $z = \Sigma^{-1}u$, относительная погрешность усиливается в $\mu(\Sigma)$ раз

$$\frac{\|\delta z\|}{\|z\|} \leq \mu(\Sigma) \frac{\|\delta u\|}{\|u\|}$$

Проблема мультиколлинеарности

Если матрица $\Sigma = F^T F$ плохо обусловлена, то:

1. решение становится неустойчивым и неинтерпретируемым, $\|\alpha^*\|$ велико;
2. возникает переобучение:
на обучении $Q(\alpha^*, X^\ell) = \|F\alpha^* - y\|^2$ мал
на контроле $Q(\alpha^*, X^k) = \|F'\alpha^* - y'\|^2$ велик

Стратегии устранения мультиколлинеарности и переобучения:

- регуляризация
- отбор признаков
- преобразование признаков

Регуляризация с точки зрения SVD-разложения

$$\alpha_{\tau}^* = (F^T F + \tau I_n)^{-1} F^T y$$

$$\alpha_{\tau}^* = U(D^2 + \tau I_n)^{-1} D V^T y = \sum_{j=1}^n \frac{\sqrt{\lambda_j}}{\lambda_j + \tau} u_j (v_j^T y)$$

Без регуляризации:

$$\alpha^* = F^+ y = U D^{-1} V^T y = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j (v_j^T y)$$

Отбор признаков

LASSO — Least Absolute Shrinkage and Selection Operator

$$\begin{cases} Q(\alpha) = \|F\alpha - y\|^2 \rightarrow \min_{\alpha}; \\ \sum_{j=1}^n |\alpha_j| \leq \kappa; \end{cases}$$

Чем меньше κ , тем больше нулевых α

Lasso vs Ridge

LASSO: Чем меньше λ , тем больше нулевых α

Ridge: коэффициенты уменьшает, но не делает их нулевыми!



Спасибо за внимание!

Вопросы?